Технико-экономическое обоснование (ТЭО): расчет совокупной стоимости владения (TCO), токеномики и юнит-экономики

Финансовая модель внедрения: Capacity Planning по рынку MOEX, архитектура двухуровневого кэширования, затраты на GPU-инференс и коммерческий эффект для брокера Т-Инвестиции.

1. Параметры предметной области и вычислительная нагрузка (Capacity Planning)

Оценка вычислительной емкости опирается на официальный реестр торгуемых инструментов ПАО Московская Биржа (MOEX):

- **Акции и депозитарные расписки:** Котировальные списки 1-го и 2-го уровней включают **~240 эмитентов**, формирующих свыше 98% объема торгов акциями физлиц.
- **Корпоративные облигации:** Сегмент ликвидных эмитентов корпоративного долга насчитывает **~350 компаний**.
- **Совокупная база активного аналитического покрытия:** $240 + 350 = \mathbf{590\text{ эмитентов}}$.

1.1. Объем входящего потока документов по законодательству РФ:

В соответствии с Федеральными законами № 208-ФЗ «Об акционерных обществах» и № 39-ФЗ «О рынке ценных бумаг», публичные компании обязаны раскрывать регулярную отчетность и существенные факты через уполномоченное агентство (Интерфакс e-disclosure.ru):
1. **Годовые и полугодовые отчеты по МСФО** (с аудиторским заключением): $590 \times 2 = \mathbf{1\,180\text{ отчетов/год}}$.
2. **Промежуточная бухгалтерская отчетность по РСБУ** (1Q и 9M): $\approx \mathbf{1\,500\text{ отчетов/год}}$.
3. **Сообщения о существенных фактах** (созывы заседаний СД, рекомендации по дивидендам, судебные споры, выпуски облигаций): $\approx \mathbf{4\,800\text{ сообщений/год}}$.
Итоговый объем входящих событий: $1\,180 + 1\,500 + 4\,800 = \mathbf{7\,480\text{ документов в год}}$ (в среднем $\approx \mathbf{30\text{ документов в рабочий день}}$). Пиковая нагрузка в сезоны раскрытия отчетности (март–апрель и август–сентябрь) составляет до **120 документов в день**.

2. Токеномика RAG-конвейера и архитектура кэширования

В RAG-архитектуре системы исключена подача 100-страничных PDF-отчетов в контекстное окно целиком (что приводило бы к потреблению до 50 000 токенов на запрос и недопустимому удорожанию инференса). Модуль гибридного векторного поиска (Qdrant) извлекает только целевые фрагменты, относящиеся к кредитному профилю эмитента.

Этап конвейера обработки	Входные токены (Prompt)	Выходные токены (Completion)	Применяемый метод оптимизации
Семантическая RAG-фильтрация	0 (локальный эмбеддинг)	0	Локальный инференс BGE-M3 на GPU (без вызова LLM)
Извлечение долговых сносок (Extractor)	3 500 токенов	400 токенов	Подача только релевантных таблиц баланса и сносок
Состязательный синтез (Synthesizer)	2 200 токенов	500 токенов	Структурированный JSON-формат вывода сценариев
ИТОГО НА 1 СОБЫТИЕ РАСКРЫТИЯ	**5 700 токенов**	**900 токенов**	**Суммарный бюджет: 6 600 токенов на документ**

2.1. Расчет коэффициента попадания в кэш (Cache Hit Rate 94.6%):

По официальным данным Московской биржи («Народный портфель»), свыше **86% совокупных вложений частных инвесторов** приходятся всего на 15 наиболее капитализированных акций (Сбербанк, Газпром, Лукойл, Яндекс, Норникель, Роснефть, Т-Банк и др.).

• **Event-Driven Pre-generation:** При публикации отчета МСФО по эмитенту система запускает мультиагентный конвейер **один раз** для всего пула клиентов. Сгенерированная карточка аудита с верифицированными коэффициентами помещается в Redis Cluster.

• **On-Demand чтение:** Когда 500 000 клиентов брокера открывают мобильное приложение, генерация не вызывается повторно — карточка извлекается из оперативной памяти за время $\le \mathbf{45\text{ мс}}$.

• **Cache Miss (5.4%):** Вызов LLM в реальном времени требуется исключительно при индивидуальных What-If симуляциях или анализе редких бумаг 3-го эшелона.

Итоговое годовое потребление токенов: $7\,480\text{ отчетов} \times 6\,600\text{ токенов} \approx 49.37\text{ млн токенов/год}$ на предгенерацию плюс $\approx 25\text{ млн токенов}$ на динамические запросы What-If. Суммарный объем $\approx 75\text{ млн токенов в год}$ легко покрывается одним GPU-сервером.

3. Совокупная стоимость владения инфраструктурой (TCO)

Для соблюдения стандартов банковской тайны и независимости от внешних провайдеров расчет выполнен для **выделенного защищенного On-Premise / Private Cloud контура** на базе российских дата-центров уровня Tier III (Selectel / Cloud.ru):

Статья аппаратных затрат	Спецификация конфигурации	Стоимость / мес.	Стоимость / год
Выделенный сервер инференса	2x NVIDIA A100-SXM4 (80GB VRAM), 128 vCPU, 512GB RAM, 4TB NVMe. vLLM с непрерывным батчингом.	250 000 руб. ($2.5k)	3 000 000 руб. ($30k)
Отказоустойчивый кластер БД	Qdrant Vector DB (3 ноды) + PostgreSQL 16 / TimescaleDB + Redis Sentinel на NVMe дисках.	60 000 руб. ($600)	720 000 руб. ($7.2k)
Сетевая инфраструктура и мониторинг	Шлюзы API (Envoy), асинхронные воркеры парсинга, Prometheus, Grafana, резервное копирование S3.	30 000 руб. ($300)	360 000 руб. ($3.6k)
ИТОГО ЗАТРАТЫ НА ИНФРАСТРУКТУРУ (TCO)	**Полный аппаратный комплекс для обслуживания 1 000 000 активных инвесторов**	**340 000 руб. / мес.**	**4 080 000 руб. / год ($40.8k)**

3.1. Удельная себестоимость на 1 активного пользователя в месяц:

$$\text{Cost per User per Month} = \frac{4\,080\,000\text{ руб.}}{1\,000\,000\text{ инвесторов} \times 12\text{ месяцев}} = \mathbf{0.34\text{ рубля в месяц}}.$$

Сравнительный бенчмарк: Затраты брокера на отправку одного сервисного SMS-уведомления составляют 1.80–2.40 руб. Таким образом, непрерывный интеллектуальный аудит портфеля на базе AI обходится банку в **5–7 раз дешевле одной сервисной SMS**.

4. Оценка экономического эффекта и доходов брокера Т-Инвестиции

Экономическая модель проекта опирается на три независимых канала монетизации и сохранения выручки:

4.1. Канал 1: Снижение оттока клиентов (Churn Reduction & LTV Preservation):

• **Проблема:** По данным брокерской индустрии, инвестор-новичок, столкнувшийся с неконтролируемой просадкой портфеля более 30–40% в первый год торговли, разочаровывается в фондовом рынке и прекращает операции с вероятностью 45–55%.

• **Стоимость привлечения клиента (CAC):** Затраты Т-Банка на привлечение одного активного клиента с фондированным брокерским счетом (маркетинг, контекстная реклама, приветственные бонусы, онбординг) составляют в среднем **4 500 руб.**

• **Эффект Copilot:** За счет своевременного предотвращения глубоких просадок отток клиентов снижается всего на **1.6 процентных пункта в год**:

$$\Delta \text{Retained Users} = 1\,000\,000 \times 1.6\% = 16\,000\text{ сохраненных активных инвесторов в год}.$$
$$\text{Экономия на удержании клиентской базы} = 16\,000 \times 4\,500\text{ руб. (CAC)} = \mathbf{72\,000\,000\text{ руб. / год}}.$$

4.2. Канал 2: Комиссионный доход от осознанных ребалансировок:

• **Механика:** Вместо «замораживания» капитала в падающих токсичных бумагах инвестор проводит ротацию в защитные активы.
• **База расчета:** 150 000 осознанных сделок в год по всей клиентской базе. Средний чек ребалансировки: 60 000 руб.
• **Тариф брокера:** 0.05% на продажу и 0.05% на покупку альтернативы (суммарно 0.10% за оборот):
$$\text{Дополнительный комиссионный доход} = 150\,000 \times (60\,000\text{ руб.} \times 0.10\%) = \mathbf{9\,000\,000\text{ руб. / год}}.$$

4.3. Канал 3: Комиссионный доход от управления ликвидностью (AUM Management Fee):

• **Механика:** Капитал из рисковых бумаг перенаправляется не во внешние банки, а в биржевой фонд денежного рынка экосистемы (БПИФ «Т-Капитал Денежный рынок» / фонд «ВИМ Ликвидность» LQDT).
• **База расчета:** Дополнительный среднегодовой прирост чистых активов фонда (AUM) составляет **12 млрд руб.**
• **Комиссия за управление (Management Fee):** Официальный сбор УК зашит в стоимость пая и составляет **0.40% годовых**:
$$\text{Комиссионный доход группы Т-Банка} = 12\,000\,000\,000\text{ руб.} \times 0.40\% = \mathbf{48\,000\,000\text{ руб. / год}}.$$

5. Инвестиционный анализ (P&L;), срок окупаемости и стресс-тест

Статья финансового плана	Экономическая сущность	Сумма (руб. / год)
Затраты на аппаратный комплекс (TCO)	Аренда GPU, кластер баз данных, сетевой контур	-4 080 000 руб.
Экономия на повторном привлечении (CAC)	Предотвращение оттока 16 000 клиентов (1.6 п.п.)	+72 000 000 руб.
Комиссионные сборы от оборота ребалансировок	150 тыс. осознанных сделок ротации капитала	+9 000 000 руб.
Сборы за управление активами фондов (AUM Fee)	Приток 12 млрд руб. в фонд ликвидности под 0.40% р.а.	+48 000 000 руб.
ВАЛОВЫЙ ЭКОНОМИЧЕСКИЙ ЭФФЕКТ	**Суммарная годовая выгода экосистемы Т-Банка**	**+129 000 000 руб.**
ЧИСТЫЙ ГОДОВОЙ ЭФФЕКТ (NPV 1Y)	**Чистая прибыль за вычетом всех затрат на инфраструктуру**	**+124 920 000 руб. / год**
РЕНТАБЕЛЬНОСТЬ ИНВЕСТИЦИЙ (ROI)	**Отношение чистой прибыли к годовым затратам TCO**	**ROI > 3 000% (< 1 мес.)**

5.1. Анализ чувствительности модели (Стресс-тестирование):

Для оценки устойчивости экономической модели к негативным рыночным шокам проведен сценарный стресс-тест:
• **Пессимистичный сценарий (Severe Stress):** Эффект снижения оттока снижается в 2 раза (до 0.8 п.п., 36 млн руб.), приток в фонды денежного рынка падает в 2 раза (до 6 млрд руб., 24 млн руб.), а стоимость аренды серверов GPU вырастает на +30% (до 5.3 млн руб.). *Итог стресс-теста:* Чистая прибыль составляет **+59.2 млн руб./год**, а рентабельность **ROI > 1 100%**.
• **Базовый сценарий (Realistic Base):** Снижение оттока на 1.6 п.п., чистый эффект **+124.9 млн руб./год (ROI > 3 000%)**.
• **Оптимистичный сценарий (Bull):** Снижение оттока на 2.5 п.п., чистый эффект **> 180 млн руб./год**.
Вывод стресс-теста: Проект сохраняет абсолютную финансовую эффективность даже при кратном падении ключевых параметров.

6. Заключение технико-экономического обоснования

Проведенные расчеты подтверждают исключительную инвестиционную привлекательность и низкие операционные риски проекта. Благодаря архитектуре двухуровневого семантического кэширования себестоимость решения минимизирована до **0.34 руб./мес.** на пользователя, что делает сервис рентабельным при масштабировании на всю миллионную клиентскую базу брокера Т-Инвестиции. Срок окупаемости капитальных и операционных затрат составляет **менее 1 месяца** с момента промышленного ввода.